CoEvoMed Rebuttal

模拟审稿意见与提分判断

评分倾向：Weak Reject（倾向拒稿）

当前回复能缓解部分疑虑，但尚不足以推动我调整至接收。

最关键的障碍是 co-evolution 的贡献尚未被充分隔离，统计可靠性的问题也没有被直接回答。材料未包含三位审稿人的原始评分，因此下表判断的是：如果我持有这些疑虑，现有回复是否足以改变我的评价。

逐位审稿人的提分倾向

对应审稿人	回复中有效的部分	我的判断
pUjh	同底座 MedVLSynther 实验、200 例标注一致性检查回应了具体问题。	暂不提分。各 agent 的必要性、retention 与 taxonomy 的增量价值仍未建立。
jcb6	原则在不同训练阶段的效用差异，有较好的实验支持。	倾向维持原判断。所要求的固定原则、固定课程对照仍然缺失。
2Nuw	增加了基线结果和若干评估解释。	暂不提分。PPO 对照、重复运行、置信区间与评估独立性的证据仍不充分。

最有说服力的已有证据

Table 8 的阶段性反转直接支持监督原则的阶段依赖性：在 VQA-RAD 上，原始原则在 R2 领先演化原则 4.22 个点，而演化原则在 R5 领先原始原则 8.26 个点。同一套原则对不同阶段学习者的效用发生反转，是论文值得保留并强化的机制证据。

评估依据：论文正文及相关附录、rebuttal_final.md 中的三份回复。本文为模拟审稿评估；不代表三位实际审稿人的决定。

01 机制贡献与实验对照

1. Table 7 检验反馈时效性，尚未单独隔离课程适应

附录 D.1（第 25 页）明确写了：实验同时替换数值能力统计和错误语义摘要，这些反馈共同指导课程分配与监督构造。因此，结果支持“当前反馈优于过时反馈”，但没有单独隔离课程适应的贡献。将这些条件直接标为“Principles only”，会使对照的解释不准确。

在已经经过 co-evolution 的 R5 模型上重新使用初始原则，也不能回答“从同一 base 出发，固定原则重构数据能获得多少收益”。这是局部训练干预与完整训练轨迹之间的区别。

> 建议删除：“the first row is an upper bound”。

没有实验或理论保证，保留课程适应一定比同时固定两项更好。两个组件可能存在交互作用，缺失的“双固定”条件不能靠这一推断补齐。“其他合成数据条件未提升，所以增益来自 co-evolution”也不能替代匹配对照。

2. 整套流程有效，尚未证明所有 agent 都不可替代

Raw data 与完整框架之间同时改变了任务格式、数据筛选、验证、课程和原则。这个比较支持整套处理流程有效，无法分别证明 selector、constructor、verifier 都不可替代。原始数据的任务格式错配为性能下降提供了合理解释，但仍需要固定原则重构等对照，量化自适应机制的额外收益。

3. PPO 的目标和动作轨迹，尚不足以建立其相对优势

“选择 repair-heavy 后能力恢复”提供了相关性证据，需要与简单分配策略比较。附录 B 写明每轮只有一次真实环境 transition，而策略先经过 800 个教师标注状态的行为克隆初始化，因此 BC-only 对照尤其关键。也应比较固定均衡分配或简单弱项优先策略。

4. 原则整体有效，尚未验证选择标准的预测能力

演化原则整体优于初始原则，没有直接验证 usable yield、semantic review 等选择标准能否预测后续学习收益。可用被接受原则与随机候选的匹配比较，或按原则版本分析选择信号与后续收益的关系，补充这一证据。

02 统计可靠性与评估独立性

1. 跨模型实验检验适用范围，重复运行估计训练波动

Qwen、Gemma 和 InternVL 上的提升支持框架的适用范围。同一设置的多次独立运行才能估计训练波动。因此，跨家族、架构和规模的结果并未直接回答审稿人要求的独立运行次数、标准差与配对置信区间。

> 需要收窄： “An effect that holds across families ⋯ is not a single-run artifact.”

应直接报告各设置的运行次数，并提供主要比较的 paired confidence intervals。IU-Xray 相对最强基线仅提升 0.92 RaTEScore，目前无法判断这个优势是否稳定。当前问题是缺少不确定性估计，不能据此断言提升不显著。

2. R7 的选择规则需要成为可执行的准则

附录 C.4（第 24 页）使用了 “most balanced overall capability profile”，但没有给出“平衡”的计算公式、归一化方式、权重及各轮内部验证值。回复增加 “predefined internal criterion” 后，仍应补齐这些细节，使他人能用同一准则选出 R7。

这一问题关系到 checkpoint 选择的可复现性。现有材料不足以认定使用了外部测试选择模型，也不足以仅凭“最平衡”的文字描述完整核验选择过程。

3. 证据耗尽提供合理解释，尚未隔离后期下降的原因

新增的证据利用率统计有价值，但“新证据减少”和“性能下降”同时发生，尚不足以支持 “Later-round declines come from the data, not our mechanisms.”。更准确的结论是：证据利用率的变化与性能进入平台期一致，支持证据耗尽这一解释。要排除机制本身的影响，还需要控制实验。

4. 重叠检查方向正确，需要具体的审计记录

不同 partition 本身无法保证不同患者或不同研究。四层检查是重要补充，还应报告各来源可用的患者 / 研究标识、近重复检测阈值，以及检查和剔除数量，尤其是 PubMedVision-IU 与 IU-Xray。

我不会据此认定存在泄漏，但当前材料也不足以将这一疑虑标记为完全解决。审计结果应让读者区分患者级、研究级、图像级检查各自覆盖的范围。

03 结论边界与修改优先级

仍需收窄的几项结论

Retention：可以澄清课程学习设定，无需补齐整套 continual-learning 基准。但多任务联合训练和 replay 不会从定义上排除能力退化。Table 7 没有独立关闭 retention 分配。当前证据支持观察到部分能力在下降后恢复，遗忘预防和稳定收敛仍缺少证据。

复杂推理：3D 输入、开放生成和长报告增加了输入或输出复杂度，不能直接推出临床推理难度更高。MedXpertQA-MM 结合专科考试问题、临床记录和检查信息 [3]；选择题形式不足以否定其评估价值。Medical Computation 上 BLEU-1 更高，也没有直接验证数值、单位或计算过程正确。

Taxonomy：200 例标注一致性支持标签可靠性，尚未证明这些维度优于原生标签。“所有机制都使用这些 cells”解释了系统如何运作，没有证明该划分的必要性。

CURE 与规模效应：已得到的 28.65 分可直接报告，并注明评估协议和域外设置。IU-Xray 不在 CURE 训练数据中，本身不足以成为排除该基线的理由。报告长度为 32B 的反转提供了合理解释；要进一步归因，需要控制生成长度。其他模型也发生反转，尚不足以证明这是 IU-Xray 的固有属性。

最可能推动提分的三类补充

优先级	需要补充的证据
1 · 机制归因	固定课程、固定原则的匹配对照；PPO 相对 BC 或简单分配策略的比较。这一项对提分影响最大。
2 · 统计可靠性	各设置的真实运行次数；主要比较的配对置信区间；有重复运行时报告训练波动。
3 · 评估可复核性	可执行的 R7 选择准则与各轮内部验证值；具体的数据重叠审计记录。

回复应使结论强度与证据范围一致。建议删除或收窄 “All agents are needed”、 “upper bound”、 “not a single-run artifact” 等表述。上述补充若支持现有主张，配合收窄未经验证的强结论，我会考虑转向 Weak Accept。

材料与参考来源

[1] CoEvoMed: Co-Evolving Supervision Principles and Medical Vision-Language Models. 用户提供的 34 页投稿 PDF；重点核对正文、附录 B-D、Tables 7-9 及相关轨迹图。
[2] rebuttal_final.md. 用户提供的三位审稿人回复。
[3] Zuo et al. MedXpertQA: Benchmarking Expert-Level Medical Reasoning and Understanding. arxiv.org/abs/2501.18362