给羽哥的1113的回复

我对照论文正文和附录（第 1–34 页）逐条核对了 `rebuttal_final.md` 中对三位审稿人（`pUjh`、`jcb6`、`2Nuw`）的回复。

总体评价是：**这三份回复的整体质量很高，数据核对非常精准，新增的几项实验/统计证据（重训 MedVLSynther、SLAKE 分类体系一致性验证、4 级去重核查、CURE-4B zero-shot、报告字数长度分析、证据池消耗日志）非常扎实且切中要害；但在少数核心问题上存在“用已有消融替代未做消融”或“偏强硬的辩护”的风险**，如果审稿人较真，可能会继续抓住不放。

下面按审稿人逐条拆解：**哪里已经足够打消疑虑，哪里还有漏洞或扣分风险**。

---

1. 数据与事实一致性核查（全部通过）

我核对了回复中引用的所有数字和论文原文：

- **Table 7 / 8 / 9 跨表拼接的数字**（如 base、R5、R2/R3 feedback、original/evolved 差值）完全准确。
- **58.3% 2D 图注占比**：对应 Figure 10(a) 中 `PMC-OA (79,858) + Quilt-1M (49,022) + ROCO (22,463) = 151,343 / 259,767 = 58.26%`，准确。
- **16/16 跨模型提升（+6.52 到 +26.76）**：对应 Qwen3-VL-8B 2D(6) + Qwen3-VL-32B 2D(6) + Gemma-3-4B-IT(2) + InternVL3-9B(2) 共 16 项，最低为 32B IU-Xray (`65.08 - 58.56 = +6.52`)，最高为 8B SLAKE (`91.60 - 64.84 = +26.76`)，完全一致。
- **3D-RAD Medical Computation +8.6 BLEU-1**：对应 Figure 9(b) 的 `37.8 - 29.2 = +8.6`，准确。
- **字符数**：`pUjh` 4,991/5,000，`jcb6` 4,330/5,000，`2Nuw` 4,994/5,000，均在限制内。

---

2. 对 Reviewer pUjh 回复的评价

做得非常好的地方

- **W3（后期掉点的原因）**：给出**“359,355 条支持事实在 R7 已使用 95%，R8 仅剩 18.0% 新证据，R10 仅剩 2.2%”**的日志解释，完美把“R7–R8 见顶后微降”归因于固定支持池耗尽后的重复训练，而不是机制失效，逻辑极有说服力。
- **Q1（MedVLSynther base model）**：直接在相同的 `Qwen3-VL-8B` 上用其官方数据和 GRPO 脚本重训了一遍，CoEvoMed-8B 依然大幅领先四项基准（67.95 / 82.48 / 91.60 / 69.40 vs 53.18 / 70.96 / 73.32 / 68.69），**彻底打消疑虑**。
- **Q2（数据开源）**：干脆利落，可打消疑虑。
- **Q3（Capability taxonomy 合理性）**：在 200 条 SLAKE 样本上测出与原生标注的一致性（capability 97.5%, $\kappa = 0.958$; modality 100%; body region 96.5%），并结合 Table 7 证明同套 taxonomy 下陈旧诊断也会掉分，**非常有力的实证回答**。

存在风险 / 尚不能完全打消疑虑的地方

1. **W1（各 Agent 角色的必要性与可替代性）存在以偏概全**：
   - 审稿人问的是：“是否真的需要**每一个** agent role（论文 App. B 定义了 5 个：selector, constructor, verifier, curriculum planner, revision agent），还是可以用更简单的流程替代？”
   - 回复中将 `raw data vs CoEvoMed` 用来证明 `selector + constructor + verifier` 三者各自都必要——这其实只验证了“不能直接用 raw data”，**并没有单独消融 verifier**（比如去掉 verifier 会掉多少？），也没有单独消融 selector。
   - 用 `R2/R3 stale feedback` 证明 `curriculum planner` 必要也有瑕疵：stale feedback 是“错误的旧反馈”，而不是“一个更简单的启发式分配策略（如均匀分配或贪心按最低分分配）”。所以说 `"no simpler process in the table substitutes them"` 只能成立在“你表格里确实没放更简单的替代策略”，审稿人可能会觉得在绕开问题。
2. **W2（论文组织结构）略显生硬**：
   - 审稿人吐槽核心设计（甚至包括训练任务配比/评估任务构成、taxonomy 定义等）被塞进附录，正文信息不足。
   - 回复完全在辩护“这样写很合理”，**没有承诺在修改版/Camera-ready 中把关键设计（如 Table 6 taxonomy、App. B 的任务比例 7:3 / 92:4:4 或 Table 3/4 概览）摘要放回正文**。此外，审稿人说的 `evaluation task composition` 既可能指 Sec. 5.1 的数据集列表，也可能指 App. B 的任务/题型配比或 Table 3/4 的细节，直接回怼“Sec. 5.1 already gives...”容易让审稿人不爽。
3. **W3（“误解”一词偏冲，且“retention ablation”与 R7 论证有漏洞）**：

- 说 `"We respectfully note a misunderstanding: CoEvoMed builds on curriculum learning, not continual learning"` 有点挑衅，而且论文自己确实在 Sec. 1、Sec. 4.1、Sec. 4.2 反复强调防止 **capability regression** 和 **retention of acquired capabilities**（甚至 Fig. 6 显示 Localization 在 R4 确实从 60.27 掉到 56.16）。承认“虽然不是顺序任务设定下的 continual learning，但多能力共同训练中确实存在能力退化（regression），我们通过全任务回放和 retention 预算来应对”会比直接说对方“误解”更好。
- `"ablated with it (Table 7)"` 有点勉强：Table 7 消融的是陈旧反馈，并没有单独消融去掉 retention 机制。
- `"R7 is where new evidence runs out, and InternVL3-9B peaks at rounds 4–6 (App. C.5). Our results therefore do not rely on the choice of R7."` 这句逻辑不太通顺（InternVL3-9B 是单任务分别训练的模型，它在 R4–6 见顶怎么能推出 CoEvoMed-8B 不依赖 R7？）。真正能说明不依赖 R7 的论据是下一句“即使到数据耗尽的 R10，也仅比峰值低 2–3 个点且仍大幅高于 R1”。

---

3. 对 Reviewer jcb6 回复的评价

做得非常好的地方

- **Q1（Raw data 掉分原因 + 固定原则重建对比）**：非常精彩。用 58.3% 图注占比解释“raw data 教错了任务（变成写 caption 而不是答题，尤其重创短答案的 SLAKE）”，配合四维问题对照表和 Table 8 (C vs D)，清楚说明了固定原则在后期跟不上学习者。

存在风险 / 尚不能完全打消疑虑的地方

1. **W1（将 R2/R3 反馈归类为 “Principles only / Curriculum adaptation = No”）在定义上不够严谨**：
   - 请注意 **Appendix D.1 (p. 25, line 1325–1328)** 原文写的是：

> *"Feedback comprises numerical capability statistics describing task-level mastery and learning changes, and summaries of error semantics characterizing unresolved failure modes. ***Both components are jointly replaced*** with records from the same source round to guide ***curriculum allocation and supervision construction***..."

- 这意味着在 R2/R3 feedback 实验里，**不只是 curriculum adaptation 用了旧反馈，supervision construction / 原则演化所依据的 error semantics 同样被替换成了旧轮次的！**把它标注为 `Principle evolution = Yes, Curriculum adaptation = No`，严格来说与附录 D.1 的实验描述有出入。
- 另外，用“喂错误/过时的 R2/R3 反馈”来代表“固定课程（No curriculum adaptation）”，严格来说不等价于“静态均匀课程（fixed/uniform curriculum）”。

2. **关于“固定原则 + 固定课程”的上界推论：**
   - 回复只看 R5→R6 这一轮，说“既然 R5 上只固定原则就已经全掉分了，那把课程也固定下来不会更好”。
   - 这能证明**在 R5 阶段**仅靠高质量合成数据不够、必须协同演化；但审稿人其实还想知道：**从 Base 到最终 R7，总涨幅（比如 VQA-RAD 从 56.76 到 82.48）里，有多少来自“高质量静态合成数据本身”，有多少来自“动态协同演化”？** 事实上，Table 8 里 R2 时用 original principles 依然在所有 6 个 benchmark 上涨分（+1.78 到 +3.90）。如果能坦诚承认“静态固定原则在早期（R2）确实能带来收益，但无法持续（到 R5 全线下降），因此协同演化是维持后期持续提升的关键”，会比硬说第一行是上界更严谨、更令人信服。

---

4. 对 Reviewer 2Nuw 回复的评价

做得非常好的地方

- **Q2（数据泄漏排查，特别是 PubMedVision-IU vs IU-Xray）**：非常硬核，明确给出了在全部 11 个 2D 和 5 个 3D 数据源与所有外部测试集之间做的 **4 层排查（IDs、路径、精确与近重复像素哈希、标准化文本）均零重叠**，直接命中审稿人最担心的点。
- **Q3 中的 CURE-4B 与 32B < 8B 问题：**
  - 补跑了 CURE-4B 在 IU-Xray 上的 zero-shot（28.65 RaTEScore，垫底），用数据说明是域偏移导致不可比；
  - 用具体平均词数（IU-Xray 参考报告 30.5 词，8B 生成 30.7 词，32B 生成 40.1 词，且 Hulu-Med、MedGemma 同样存在大模型在 IU-Xray 上低于小模型的现象；而在报告更长的 MIMIC-CXR 上 32B 反超 8B）完美解释了 32B 倒挂原因。这是整份 rebuttal 里最漂亮的回答之一。

存在风险 / 尚不能完全打消疑虑的地方（`2Nuw` 是最可能继续挑刺的审稿人）

1. **Q1 中的 “PPO vs 更简单分配策略” 没有正面回答：**

- 审稿人明确问：`including PPO's advantage over simpler allocation strategies?`
- 回复只描述了 PPO 在 R1–R7 选了哪些动作（balanced → weakness-focused → ... → repair-heavy），**没有和任何更简单的策略（如均匀分配、贪心选最低分能力、或仅用 BC 初始化不更新 PPO）做对比实验**。审稿人看到这里很容易认为“你还是没证明 PPO 比简单启发式强”。

2. **Q1 中的 “单个原则选择标准与后续收益的关系” 仅靠总体对照支撑：**
   - 回复引用了 Table 8（R5 时进化后的原则整体优于初始原则）和筛选机制的设计逻辑，但并没有给出“单个被选中的原则 vs 被拒绝/未筛选的原则”或“筛选阈值（如 $\rho_{\text{pair}}, \Delta_{\text{use}}$）消融”的定量证据。
3. **Q3 中的 “独立运行次数”与“配对置信区间（paired CIs）”没有给出：**
   - 审稿人问：`How many independent runs underlie the main results, and could you provide standard deviations and paired confidence intervals?`
   - 回复用“4 个不同模型家族/规模独立跑了全流程，16/16 全部提升”来说明不是单次随机波动，这个思路在计算受限的 LLM 训练中可以理解，但有两点欠缺：
     - **没有明说主实验具体跑了几次**（诚实说明由于 24×A100 多轮全参微调算力限制，每个 backbone/scale 为 1 次完整训练，反而更坦诚）。
     - **完全没提供 paired confidence intervals（配对置信区间）！**注意：计算测试集上的 **paired bootstrap confidence intervals（配对自助法置信区间）是不需要重训模型的**，只需要用已经保存的 checkpoint 预测结果即可算出（例如 VQA 准确率或 IU-Xray 上比 Hulu-Med-7B 高 0.92 RaTEScore 的 95% CI / p-value）。审稿人专门质疑 IU-Xray 只领先 0.92 分是否统计显著，如果不补一个测试集上的 paired bootstrap CI，这里可能会留隐患。
4. **Q4（为什么没测 MedXpertQA-MM / MMMU Health & Medicine）的回击方式有风险：**
   - 回复把 MedXpertQA-MM 和 MMMU 定性为“2D 图片上的选择题（multiple choice on 2D images）”，并称 CoEvoMed 的任务（写报告、3D 推理、3D 测量）**“harder than multiple choice on 2D images”**。
   - 这其实**偷换了难度维度**：审稿人批评的是缺乏 **expert-level, complex medical reasoning（专家级复杂医学知识/临床鉴别推理）**，即考题背后的多步临床逻辑深度；而 PMC-VQA、M3D-VQA 虽然也是选择题，但主要考的是视觉识别/基础属性，知识深度和 MedXpertQA-MM / MMMU（执业医师/医学院级复杂推理）不是一回事。直接说人家“只是 2D 选择题、不如我们的任务难”，可能会引起熟悉医学评测基准的审稿人的反感。

---

5. 总结：能否打消审稿人疑虑？

审稿人	整体把握	已彻底解决的问题	仍有隐患/建议微调的点
pUjh	中高	Q1 (MedVLSynther)、Q2 (数据公开)、Q3 (Taxonomy 相关性验证)、W3 后期掉点原因 (证据池 95% 耗尽)	1) W1 未真正单独消融 verifier/selector 或对比简单分配策略，结论别说太满； 2) W2 建议承诺 camera-ready 将核心设定表/比例前移到正文； 3) W3 删掉“misunderstanding”和 InternVL 见顶的弱推论。
jcb6	高（审稿人本身偏正面）	Q1 (58.3% 图注解释 raw data 掉分 + R5 固定 vs 演化对比)	1) 按 App. D.1，R2/R3 feedback 同时改了课程反馈和错误语义，标注“Principles only”时建议措辞更准确； 2) 承认固定原则在早期 (R2) 有效但在后期 (R5) 失效，而不是把 R5 固定原则直接当成全过程上界。
2Nuw	中（取决于其对统计和复杂推理的执念）	Q2 (4 级零重叠排查)、Q3 (CURE-4B zero-shot、32B IU-Xray 长度效应解释)	1) 如手头有预测结果，**强烈建议补算测试集 paired bootstrap CI**（尤其 IU-Xray +0.92）； 2) 坦诚说明每个设定跑 1 次完整训练的原因，及 PPO 对比简单策略（如作为 limitation/future work，不硬拗）； 3) Q4 不要贬低 MedXpertQA-MM/MMMU 是“2D MCQ”，应承认它们侧重**知识型临床考试推理**，作为当前评测的互补方向并在未来工作中纳入（或如有能力跑一个 zero-shot 评测就更好）。

如果你的回复字数已经非常接近 5,000 字符上限（`pUjh` 剩 9 字符，`2Nuw` 剩 6 字符），**最优先、零算力成本且性价比最高的修改**是：

1. 在 `2Nuw` 的 Q3/W2 补上基于已有预测结果的 **paired bootstrap 95% CI**（或者如果暂时来不及算，至少坦诚交代是 1 次完整训练并调整 Q4 对 MedXpertQA-MM/MMMU 的措辞，删掉“which is harder than multiple choice on 2D images”这种容易拉仇恨的对比）；
2. 在 `pUjh` 的 W2/W3 柔化语气，承诺在修订版把 App. B/Table 6 关键设计摘要移入正文，删去“misunderstanding”和逻辑较弱的 InternVL R4–R6 类比。